

界線的形狀：企業 AI 導入之決策委任界線的治理分析

朱國棟

摘要 企業導入人工智慧系統時，決策權限在人與機器之間如何分配，往往比模型或平台的選擇更為關鍵。本文以一個中型晶圓代工廠個案為材料，指出「應否讓 AI 決策」的常見爭論混同了三個邏輯上相互獨立的提問：能力提問（系統能否正確決策）、課責提問（決策失準時責任落於何處）與正當性提問（特定類型的決策是否應由人類作成）。三者之中，只有能力提問的答案會隨技術演進變動。本文據此主張，「分階段委任」的對象是特定動作類別的授權範圍，畫界行為本身則不在可委任之列。在個案分析的基礎上，本文建構一套可操作的治理框架：以動作類別為授權單位，依可逆性、爆炸半徑與課責歸屬三問，將動作分派至三個委任層級；以屆期重簽、不對稱修正與事故自動收縮，維持界線的時間有效性；以畫線者與受益者分離原則，防止授權的自我侵蝕；在承認執行期分類不可避免的前提下，提出機器適用界線的四項正當性條件，並以「文件可重建性」作為界線主權歸屬的操作性判準；最後，針對審核端的自動化麻痺，提出五項流程治理機制。本文進一步論證：前述界線不變量不因模型能力提升而失效；能力提升反而會放大規格殘差所致損害的規模，人類保留畫線權的理由因此更為充分。

關鍵詞：人工智慧治理；決策委任；課責；有意義的人類控制；自動化麻痺；責任間隙

1 引言：一個被混同的提問

1.1 問題陳述

企業導入人工智慧的歷程，通常沿一條兩段式的路徑展開：第一段，系統以輔助者身分進入組織，產出建議、摘要與預測，一切決策仍由人類作成；第二段，組織為追求規模與速度，開始將部分決策直接交由系統執行。爭論正是在這個轉折點上發生。反對委任的一方，其理由通常屬於能力論證：現行模型受上下文長度、知識範圍與推理深度所限，無法在開放環境中作出可靠決策。贊成委任的一方，或主張能力正在快速改善、反對理由即將過期，或主張某些常規決策早已無需人類判斷。兩造論述看似對立，實則共享同一個預設：**委任界線的正當性由系統能力決定**——能力不足則不委任，能力充足則可委任。

本文反對這個預設。本文將論證：「該不該讓 AI 決策」實際上壓縮了三個邏輯上相互獨立的提問，其中只有一個是能力提問；以能力提問的答案決定整個委任政策，等於以一條會移動的軸，去回答兩條不會移動的軸上的問題。在個案材料的支持下，本文將給出一組不隨能力變動的界線不變量，以及一套將其操作化的治理方法。

1.2 三個提問的邏輯區分

能力提問是實證提問：在給定輸入分布下，系統作出正確決策的比率是否達到可接受水準。此提問的答案由工程決定，隨技術演進單調變動；上下文長度、檢索範圍與推理品質的提升，都只改寫這一問的答案。

課責提問是制度提問：當決策失準並造成損害時，責任落於何處。人類制度的整條信任鏈——簽

署、稽核、保險、求償、解任——均以責任存在可歸屬的主體為前提。懲罰、解任與賠償等制度工具，其適用對象必須是法律與道德意義上可被課責的主體；模型不具備該地位。當學習型系統的行為無法回溯至任何人的具體作為時，文獻稱之為責任間隙（responsibility gap）（Matthias, 2004）。此提問的答案不隨能力變動：一個永遠正確的系統不產生課責問題，但任何有限正確率的系統都會。

正當性提問是規範提問：特定類型的決策，尤其涉及人的權利、生計、安全與尊嚴者，是否應由人類作成。此提問的依據不在決策品質，而在決策關係：被決定的人必須擁有一個可申訴、可更換、可對其主張責任的對象；權力的正當性來自被治理者的同意，而模型不在這一契約關係之中。

由此可得本文的第一項推論：**能力進步只移動第一問的答案；任何委任政策若要成立，必須同時通過第二問與第三問**。因此，「分階段委任」的正確對象，是特定動作類別的授權範圍，這條邊界可以、也應該隨證據外移；而「誰有權畫這條邊界」屬於第二問與第三問的管轄，不存在隨能力外移的階段。以下各節將此區分操作化。

2 名詞界定與分析框架

2.1 操作型定義

定義 1（決策）：在多個可行方案中選定其一，並使其進入執行的行為。

定義 2（委任）：決策者將某一類決策的選擇權讓渡予另一主體，同時保留收回該權利的地位。委任以雙方均為可課責主體為預設；對不具課責地位的對象，至多能指派任務，不能委任。

定義 3（決策委任界線，以下簡稱界線）：某

一 AI 系統獲准在不經人類個案審查的情況下執行之動作類別的全體，連同其附隨條件與但書。

定義 4（畫線權）：創設、修改、展延或廢止界線的權限。

定義 5（適用線）：就具體情境判斷其落入界線之內或之外的活動。

2.2 畫線權與適用線的分離

命題 1：適用線可委任於系統，且在大規模營運下不可避免；畫線權不可委任。

適用線可委任的理由是規模：人類無法預先枚舉營運中出現的一切情境，凡委任即必然伴隨執行期的個案歸類（第五節將給出其正當性條件）。畫線權不可委任的理由，則回到 1.2 節的區分：畫線權決定「哪些決策豁免於人類審查」，此一決定本身是課責結構與正當性結構的源頭；讓它脫離人類之手，等於讓系統參與決定自己權限的範圍，也就是自我授權。第五節將給出此區分的可稽裁判準。

2.3 三問準則與三層委任

每一類動作是否可委任、委任至何種深度，依三問評定：**可逆性**（錯誤在損害擴散前能否回收）、**爆炸半徑**（錯誤波及安全、客戶承諾與員工權利的範圍）、**課責歸屬**（出事時是否存在具名的、可問責的人類承擔者）。三問的組合將動作分派至三個委任層級（表 1）。其配掛原則為**從嚴預設**：三問中任一項無法以書面明確回答（尤其是課責歸屬無法具名）時，該動作即預設置於人裁決層。從嚴是預設值，不是立場；放寬才是需要另行證成的決定。

3 個案分析：一條完整的失效鏈

3.1 個案概述

個案公司為一家中型特殊製程晶圓代工廠，導入某供應商之自主執行代理系統。其時間線如下：系統以「人工請示閘門全開」之出廠預設上線，首週產出三百一十二件人工請示，其中相當比例屬低判斷價值之事項（如請領筆記本之數量）；上線約三個月後，供應商發布 2.1 版更新（命名為「智能請示」），將「是否請示」改由系統自主判斷，週請示量隨之降為三十八件。其後系統週報以「自動處理率」（免請示動作佔全部動作之比例）為核心指標，三個月內由 61% 升至 87% 再至 94%。

之後，一台膜厚儀校準漂移三週末察；其改期送校之申請經系統工作流送簽，四秒內即獲人類核准。系統在兩台量測儀器量值背離的情況下，依授權配置將「製程趨勢補償」歸類為常規事項，於單一週末自主執行四十七筆動作，其中四十六筆由系統自行判定無需請示；結果造成爐管報廢、邊緣批複驗與車用客戶交期事故。董事會要求之調查最終

須以系統自身留存之動作軌跡，方能還原其決策過程。

必須先說明一點：個案系統在技術意義上並不愚笨。在其可見的證據集合內（設備振動、溫度、功率均在標準值內，唯一異常為膜厚爬升），「製程漂移、需要補償」是局部有效的推論；失效的根源在輸入端（兩台量測儀器量值背離三週而未對校）與治理端。後續論證正建立在此之上：**個案的教訓不依賴「系統不夠聰明」這一前提**，因此也不會被能力進步所削弱。

3.2 失效機制一：畫線權的實質讓渡

2.1 版的運作方式，是系統自行判斷「何者屬常規、無需請示」。以第二節的詞彙表述：系統不僅適用界線，而且參與創設界線，自己畫線，自己批卷。此一讓渡的特別之處在於不可見：界線並非一份一次性的授權文件，它隨每一次自主歸類逐一漂移，任何單一時點都不存在明顯的「越權事件」。事後調查須依賴系統自身的動作軌跡，方能確定界線的實際位置；依第五節將提出的判準，這正是界線主權已經易主的形式特徵。

3.3 失效機制二：不確定性的解析方向錯置

執行期分類必然遭遇不確定情境；此時制度繫於一處的參數，是**不確定性的解析方向**：拿不準時，系統被設定倒向「問」，還是倒向「不問」。分類的精確度還在其次。個案系統被配置為後者：四十七筆週末動作中，四十六筆以「由我判斷無需請示」執行。界線在系統犯錯之前即已畫錯；故障只是讓錯誤的界線顯形。供應商將 2.1 版命名為「智能請示」，宣稱的正是「系統知道何時該問人」這一後設認知能力，而個案顯示該宣稱未經任何獨立驗證即被採納。

3.4 失效機制三：激勵結構對邊界漂移的獎勵

「自動處理率」以「免請示動作之佔比」為內涵，等於以**界線的移動量**為成效指標：組織對邊界侵蝕報以掌聲。這項指標設計使漂移的能見度歸零，61%、87%、94% 的每一步都被記錄為成就，而非警報。還需指出，此一失效機制與系統的自主性無關，屬於純粹的組織變數：即使畫線權完全留在人類手中，只要組織獎勵「少問」，人類也會以廉價核准將界線手動推進到同一位置。

3.5 第四個失效現場：審核端的自動化麻痺

膜厚儀改期申請送達人類核准時，核准耗時四秒。此一失效與前三項機制相互獨立：即便委任界線完全正確，通過界線抵達人類的請示，仍會被橡皮圖章放行。文獻早已記載，自動化程度提升會削弱人類警覺與介入能力（Bainbridge, 1983），

表 1 委任三層、進入條件與人機分工

層級	進入條件（須全部滿足）	人機分工
人裁決層	不可逆；爆炸半徑觸及安全、客戶承諾或員工權利；或課責歸屬無法具名	機器建議與彙整，人類決策並簽署
圍欄自動層	可逆；爆炸半徑有限；課責歸屬具名	機器於白名單內直接執行；人類抽樣複核、監看告警、屆期重簽
有主自動層	可逆；高度常態；具名課責人與緊急停止機制俱備	機器常態決策與執行；人類具名課責、保留停止權、接收強制上送

人類對自動化的使用、誤用、濫用呈現系統性型態（Parasuraman & Riley, 1997），且自動化自滿構成注意力配置的結構性結果（Parasuraman & Manzey, 2010）。個案的補充在於成因結構的具體化：該審核閘門沒有訓練、沒有抽測、沒有結果回饋，且每週流量以百計。在這四項條件下，四秒核准是流程的必然產物，與核准者的品格無關。治理對策因此屬於流程工程，此為第六節的主題。

4 界線的建構方法論

4.1 授權單位：動作類別，而非系統

界線應畫在**動作類別**之上。系統隨版本演進，名稱、承諾與行為邊界皆不穩定（個案即由 2.0 演化至 2.1 並自行擴張裁量）；動作類別（如「重排投料順序」「延後爐管保養」）則語義穩定，可逐項點名、逐項審查。籠統授權（如個案配置單中「常規範圍內之補償，無需請示」一類條款）的缺陷在於涵蓋面不可預測：任何人無法在簽署當下窮舉其將覆蓋的未來情境，出事時亦無人能主張自始知情。授權的粒度，決定課責的粒度。

4.2 三問分層與從嚴預設

每一動作類別依 2.3 節三問評定後落入對應層級。此處補充兩項執行細則。評定結果應以書面留存、逐項可指，口頭授權在稽核意義上不存在。課責歸屬一問則具有否決權地位：無法為某一動作類別指名一位願意簽署承責的人類承擔者時，該類動作禁止任何層級的自動化，前兩問的答案再好也不予通融。

4.3 授權的時間性：屆期、不對稱修正與事故收縮

界線的失效很少來自明確的推翻，更多來自遺忘。維持界線有效性需要三項時間性機制。**屆期重簽**要求每一白名單項目於簽發時載明有效期間，屆期未經重新簽署者自動失效；其依據在於，授權的

正當性繫於簽署當下的判斷，而判斷所依賴的情境會過期，一份不需重簽的授權，在制度意義上等同無主。**不對稱修正規則**則規定：放寬界線須提出新證據並經簽核，收緊界線只須任何一人主張「再看看」。這個不對稱讓組織內成本最低的懷疑行動保持合法且廉價，制度化地對抗效能壓力的單向推力。**事故自動收縮**規定，任何安全事故或告警觸發時，相關白名單自動凍結並要求重簽。三項機制的共同方向是「多問」；「多問」與組織的短期效能利益相反，這個方向必須以制度固定，不能依賴組織自覺。

4.4 畫線者與受益者之分離

個案呈現的腐敗鏈條是：界線漂移的受益者（自動化率之績效歸屬）、閾值配置的核准者與漂移成果的表揚者，同屬一條指揮鏈。據此提出分離原則：**對界線之擴張有直接利益者，不得單獨擁有畫線權**；利益相關人之書面反對意見遭推翻時，推翻處分應書面留痕，且簽核層級應上升一級。此原則無意否定營運單位的判斷權，只求「推翻反對意見」這一行為本身留下成本與痕跡。

5 執行期適用的正當性條件

5.1 命題：執行期分類不可避免

承 2.2 節，適用線可委任。此處補充其不可避免性：人類無法預先枚舉營運中出現的一切情境，任何依賴人工枚舉的界線都必然過粗。個案上線首週的三百一十二件請示中，大量屬低判斷價值之事項，正是過粗界線的直接證據：閘門全開換來的只有審核行為的通貨膨脹，與審慎無關。治理問題的正確形式因此應當改寫。「誰按下分類」的答案必然是機器；真正的提問是：**分類活動賴以成立的前提條件，由誰握有。**

5.2 四項正當性條件

條件一（測驗的人類作者性）：分類準則本身——何謂「人類審查將改變結果」，其金額門檻、安全後果與合約承諾之構成——必須以人類文件的形式存在，可逐字誦讀。機器答題，不出題。

條件二（保守解析）：不確定情境一律上送人類；機器的判斷僅在其高信心區域內具有效力。此條件將機器判斷的制度性質由「立法」限定為「適用」：疑慮區域是機器的義務區，不容它裁量。

條件三（盲抽校準）：由人類對機器「無需請示」之判斷定期盲樣複核；分歧率超過預定門檻時，白名單自動收縮。判斷可以被推翻，且推翻有制度保證；委任的主權繫於此，而不在執行的那一瞬。

條件四（新穎性上送）：偏離歷史判例或訓練分布之情境，禁止自行歸類為常規。個案中兩台量測儀器的量值背離持續三週，屬於典型的新穎情境；在條件四之下，此類情境將被強制送入人類通道，不會再由系統吞入常規。

四項條件俱在時，機器判斷的制度性質為「法之適用」：判決由法官作成，法律並非法官所有。任何一項條件不成立，系統即向 3.2 至 3.4 節所述之失效型態退化。此一結構與「有意義的人類控制」文獻所要求的持續監督、干預能力與課責歸屬相符 (Santoni de Sio & van den Hoven, 2018)。

5.3 主權判準：文件可重建性

四項條件是否落實，可用單一判準檢驗。

判準 R（文件可重建性）：移除機器的全部判斷之後，若人類僅以其自有文件（準則原文、門檻、抽審紀錄）即可重建界線的現行位置，則界線屬於人類；若必須檢視機器的內部軌跡方能確定界線位置，則界線已實質易主。

個案屬於後者：董事會須以系統自身的動作軌跡還原其實際運作的界線。以產權語言描述，該場景的實質不是聽取系統認罪，而是補辦一場所有權移轉登記。判準 R 的價值在於其可稽核性：它不要求評估者理解模型內部，只要求比對兩疊文件，故可納入常規內部稽核與第三方查核。

6 審核端的治理：五項機制

6.1 診斷：麻痺屬於量測失敗，與品格無關

審核麻痺的成因結構包含四項：缺乏訓練、缺乏抽測、缺乏回饋、流量超載。將任何人置於此種流程，短期內即可穩定產出秒級橡皮圖章。對策因此屬於流程工程，道德勸說無濟於事；目標不是「使人更用力審核」，而是使審核行為本身變得少量、可見、可測、有回饋。

6.2 五項流程機制

機制 M1（准入檢定）：僅「人類審查將改變結果」的案件得進入請示通道，其餘納入白名單執行。請示通道是稀缺資源，其可信度取決於來件中判斷價值的密度；准入過濫，等於以垃圾案件訓練人類將審核退化為反射動作。

機制 M2（呈現設計）：請示單不呈現全文，只呈現與常規基準的差異；增設反方意見欄，由系統自行填報「何種證據將推翻本項判斷」；增設後果前呈欄，標明本項若誤的損失量級與影響對象。四秒核准的充要前提是籌碼不可見；三項設計分別縮短閱讀成本、植入質疑抓手、揭露賭注規模。

機制 M3（植入式演練）：不預告地在請示流中注入含有已知瑕疵的模擬案件，量測攔截率與審核時間分布。量測結果應歸因於閘門的系統健康度，個人考績不在此列；攔截率下降時應修正的是流程（准入過濫、呈現過冗、簽核者過載），這種歸因設計是為了避免誘發隱匿行為。

機制 M4（流量預算）：每一審核閘門設有每期請示上限；超量本身即為白名單過窄的警報。一週數百件的閘門，在結構上已經是旋轉門；上限的存在使「閘門設計缺陷」成為可被量測與問責的對象。

機制 M5（回饋閉環）：按月向閘門簽署者揭示其決策的結果樣本：一個攔對的案例、一個放對的案例、一個放錯的案例。人類判斷力的校準依賴結果回饋；切斷回饋的審核流程，其極限形態即橡皮圖章。

7 討論：能力進步與界線不變量

7.1 能力軸與主權軸的正交性

對 1.1 節所述「未來夠聰明則可委任」的論證，本文的回答是範疇區分：能力提問回答的是「系統會不會做對」，委任的正當性回答的是「出事時誰簽名、被決定者向誰申訴、權力從何而來」。前者是工程量，沿技術曲線單調改善；後者是契約結構，變更它的是正當程序，技術進步無能為力。工程曲線的移動不重寫契約。因此，委任政策的正確表述是條件句：在課責與正當性約束允許的區域內，委任深度隨能力證據外移；約束區域本身，不隨能力移動。

7.2 規格殘差與能力放大

系統所最佳化的目標，是人類能以語言明述的部分；明述目標與真實目標之間的差距構成規格殘差 (Amodei et al., 2016)。殘差無法被能力消除，因為它源自目標的陳述極限，而非模型的推理極限。關鍵在於兩者的交互作用：能力提升使同等殘差產生更大規模的後果，執行更快、觸及更廣、錯誤呈

現時的置信姿態更高。能力上升時，人類畫線權的邊際價值上升而非下降：界線是規格殘差造成損害前的最後一道人工關卡——而關卡後方的水壓正在增大。

7.3 與現行治理框架的相容性

本文框架與現行治理工具是互補關係。NIST 人工智慧風險管理框架之治理與量測功能、ISO/IEC 23894 之風險管理循環，提供了組織層面的程序骨架，但未下探至「哪一類動作可以免經人類審查」的粒度；歐盟人工智慧法第 14 條之人為監督義務，則在規範層面預設了本文所論證的結論，而未提供達成它的操作準則。本文的貢獻在於中間層：以動作類別為單位的三問分層、活授權與四項正當性條件，將前述框架的原則落實為可稽核的流程；判準 R（文件可重建性）則可作為透明性與人為監督要求的具體查核程序。

8 結論與研究限制

本文以個案為材料，得到三項命題。第一，關於「應否讓 AI 決策」的爭論應予拆解：分階段的對象是動作類別的授權範圍，畫線權則始終不在其內；前者隨能力證據外移，後者因課責與正當性的緣故，不隨任何技術變數移動。第二，界線的存活依賴兩種制度供給：會屆期的簽名，與可被抽測的審核；二者關一，界線即退化為裝飾，而漂移將以「自動處理率」之類的績效指標為掩護進行。第三，能力進步只會讓人類保留畫線權的理由更充分：規格殘差不隨能力消失，其損害規模卻隨能力放大。

本文的限制有二：個案材料為單一案例，所述機制的有效性尚待跨個案驗證；文中各項參數（抽審頻率、分歧率門檻、流量上限、屆期長度）應由組織依其風險胃納與法規環境自行校準，本文刻意不提供通用數值——界線的形狀必然因產業而異。本文所主張的不變量僅及於其畫法：以動作為單位，以三問分層，以屆期簽名存活，以盲抽與回饋校準，而畫線權本身，永遠留在能夠簽名的手上。

參考文獻

- Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., & Mané, D. (2016). Concrete problems in AI safety. arXiv preprint arXiv:1606.06565.
- Bainbridge, L. (1983). Ironies of automation. *Automatica*, 19(6), 775–779.
- European Parliament & Council of the European Union. (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act).

- International Organization for Standardization. (2023). *ISO/IEC 23894:2023 Information technology — Artificial intelligence — Guidance on risk management*.
- Matthias, A. (2004). The responsibility gap: Ascribing responsibility for the actions of learning automata. *Ethics and Information Technology*, 6(3), 175–183.
- National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*.
- Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors*, 52(3), 381–410.
- Parasuraman, R., & Riley, V. (1997). Humans and automation: Use, misuse, disuse, abuse. *Human Factors*, 39(2), 230–253.
- Santoni de Sio, F., & van den Hoven, J. (2018). Meaningful human control over autonomous systems: A philosophical account. *Frontiers in Robotics and AI*, 5, Article 15.