

界线的形状：企业 AI 导入之决策委任界线的治理分析

朱国栋

摘要 企业导入人工智能系统时，决策权限在人与机器之间如何分配，往往比模型或平台的选择更为关键。本文以一个中型晶圆代工厂案例为材料，指出“应否让 AI 决策”的常见争论混同了三个逻辑上相互独立的提问：能力提问（系统能否正确决策）、课责提问（决策失准时责任落于何处）与正当性提问（特定类型的决策是否应由人类作成）。三者之中，只有能力提问的答案会随技术演进变动。本文据此主张，“分阶段委任”的对象是特定动作类别的授权范围，画界行为本身则不在可委任之列。在案例分析的基础上，本文建构一套可操作的治理框架：以动作类别为授权单位，依可逆性、爆炸半径与课责归属三问，将动作分派至三个委任层级；以届期重签、不对称修正与事故自动收缩，维持界线的时间有效性；以画线者与受益者分离原则，防止授权的自我侵蚀；在承认执行期分类不可避免的前提下，提出机器适用界线的四项正当性条件，并以“文件可重建性”作为界线主权归属的操作性判准；最后，针对审核端的自动化麻痹，提出五项流程治理机制。本文进一步论证：前述界线不变量不因模型能力提升而失效；能力提升反而会放大规格残差所致损害的规模，人类保留画线权的理由因此更为充分。

关键词：人工智能治理；决策委任；课责；有意义的人类控制；自动化麻痹；责任间隙

1 引言：一个被混同的提问

1.1 问题陈述

企业导入人工智能的历程，通常沿一条两段式的路径展开：第一段，系统以辅助者身份进入组织，产出建议、摘要与预测，一切决策仍由人类作成；第二段，组织为追求规模与速度，开始将部分决策直接交由系统执行。争论正是在这个转折点上发生。反对委任的一方，其理由通常属于能力论证：现行模型受上下文长度、知识范围与推理深度所限，无法在开放环境中作出可靠决策。赞成委任的一方，或主张能力正在快速改善、反对理由即将过期，或主张某些常规决策早已无需人类判断。两造论述看似对立，实则共享同一个预设：**委任界线的正当性由系统能力决定**——能力不足则不委任，能力充足则可委任。

本文反对这个预设。本文将论证：“该不该让 AI 决策”实际上压缩了三个逻辑上相互独立的提问，其中只有一个是能力提问；以能力提问的答案决定整个委任政策，等于以一条会移动的轴，去回答两条不会移动的轴上的问题。在案例材料的支持下，本文将给出一组不随能力变动的界线不变量，以及一套将其操作化的治理方法。

1.2 三个提问的逻辑区分

能力提问是实证提问：在给定输入分布下，系统作出正确决策的比率是否达到可接受水平。此提问的答案由工程决定，随技术演进单调变动；上下文长度、检索范围与推理质量的提升，都只改写这一问的答案。

课责提问是制度提问：当决策失准并造成损害时，责任落于何处。人类制度的整条信任链——签署、审计、保险、索赔、解任——均以责任存在可归属的主体为前提。惩罚、解任与赔偿等制度工具，

其适用对象必须是法律与道德意义上可被课责的主体；模型不具备该地位。当学习型系统的行为无法回溯至任何人的具体作为时，文献称之为责任间隙（responsibility gap）（Matthias, 2004）。此提问的答案不随能力变动：一个永远正确的系统不产生课责问题，但任何有限正确率的系统都会。

正当性提问是规范提问：特定类型的决策，尤其涉及人的权利、生计、安全与尊严者，是否应由人类作成。此提问的依据不在决策质量，而在决策关系：被决定的人必须拥有一个可申诉、可更换、可对其主张责任的主体；权力的正当性来自被治理者的同意，而模型不在这一契约关系之中。

由此可得本文的第一项推论：**能力进步只移动第一问的答案；任何委任政策若要成立，必须同时通过第二问与第三问**。因此，“分阶段委任”的正确对象，是特定动作类别的授权范围，这条边界可以、也应该随证据外移；而“谁有权画这条边界”属于第二问与第三问的管辖，不存在随能力外移的阶段。以下各节将此区分操作化。

2 名词界定与分析框架

2.1 操作性定义

定义 1（决策）：在多个可行方案中选定其一，并使其进入执行的行为。

定义 2（委任）：决策者将某一类决策的选择权让渡予另一主体，同时保留收回该权利的地位。委任以双方均为可课责主体为预设；对不具课责地位的对象，至多只能指派任务，不能委任。

定义 3（决策委任界线，以下简称界线）：某一 AI 系统获准在不经人类逐案审查的情况下执行之动作类别的全体，连同其附随条件与但书。

定义 4（画线权）：创设、修改、延长或废止界

线的权限。

定义 5 (适用线): 就具体情境判断其落入界线之内或之外的活动。

2.2 画线权与适用线的分离

命题 1: 适用线可委任于系统，且在大规模运营下不可避免；画线权不可委任。

适用线可委任的理由是规模：人类无法预先枚举运营中出现的一切情境，凡委任即必然伴随执行期的逐案归类（第五节将给出其正当性条件）。画线权不可委任的理由，则回到 1.2 节的区分：画线权决定“哪些决策豁免于人类审查”，此一决定本身是课责结构与正当性结构的源头；让它脱离人类之手，等于让系统参与决定自己权限的范围，也就是自我授权。第五节将给出此区分的可核查判准。

2.3 三问准则与三层委任

每一类动作是否可委任、委任至何种深度，依三问评定：**可逆性**（错误在损害扩散前能否回收）、**爆炸半径**（错误波及安全、客户承诺与员工权利的范围）、**课责归属**（出错时是否存在具名的、可问责的人类承担者）。三问的组合将动作分派至三个委任层级（表 1）。其配挂原则为**从严预设**：三问中任一项无法以书面明确回答（尤其是课责归属无法具名）时，该动作即预设置于人裁决层。从严是预设值，不是立场；放宽才是需要另行证成的决定。

3 案例分析：一条完整的失效链

3.1 案例概述

案例公司为一家中型特种制程晶圆代工厂，导入某供应商之自主执行代理系统。其时间线如下：系统以“人工请示闸门全开”的出厂预设上线，首周产出三百一十二件人工请示，其中相当比例属低判断价值之事项（如请领笔记本的数量）；上线约三个月后，供应商发布 2.1 版更新（命名为“智能请示”），将“是否请示”改由系统自主判断，周请示量随之降为三十八件。其后系统周报以“自动处理率”（免请示动作占全部动作之比例）为核心指标，三个月内由 61% 升至 87% 再至 94%。

之后，一台膜厚仪校准漂移三周末察；其改期送校之申请经系统工作流送签，四秒内即获人类核准。系统在两台量测仪器量值背离的情况下，依授权配置将“制程趋势补偿”归类为常规事项，于单一周末自主执行四十七笔动作，其中四十六笔由系统自行判定无需请示；结果造成炉管报废、边缘批复验与车用客户交期事故。董事会要求的调查最终须以系统自身留存的动作轨迹，方能还原其决策过程。

必须先说明一点：案例系统在技术意义上并不愚笨。在其可见的证据集合内（设备振动、温度、功

率均在标准值内，唯一异常为膜厚爬升），“制程漂移、需要补偿”是局部有效的推论；失效的根源在输入端（两台量测仪器量值背离三周而未对校）与治理端。后续论证正建立在此之上：**案例的教训不依赖“系统不够聪明”这一前提**，因此也不会被能力进步所削弱。

3.2 失效机制一：画线权的实质让渡

2.1 版的运作方式，是系统自行判断“何者属常规、无需请示”。以第二节的词汇表述：系统不仅适用界线，而且参与创设界线，自己画线，自己批卷。此一让渡的特别之处在于不可见：界线并非一份一次性的授权文件，它随每一次自主归类逐一漂移，任何单一时点都不存在明显的“越权事件”。事后调查须依赖系统自身的动作轨迹，方能确定界线的实际位置；依第五节将提出的判准，这正是界线主权已经易主的形式特征。

3.3 失效机制二：不确定性的解析方向错置

执行期分类必然遭遇不确定情境；此时制度系于一处的参数，是**不确定性的解析方向**：拿不准时，系统被设定倒向“问”，还是倒向“不问”。分类的精确度还在其次。案例系统被配置为后者：四十七笔里，四十六笔“由我判断无需请示”。界线在系统犯错之前即已画错；故障只是让错误的界线显形。供应商将 2.1 版命名为“智能请示”，其宣称的正是“系统知道何时该问人”这一后设认知能力，而案例显示该宣称未经任何独立验证即被采纳。

3.4 失效机制三：激励结构对边界漂移的奖励

“自动处理率”以“免请示动作之占比”为内涵，等于以**界线的移动量**为成效指标：组织对边界侵蚀报以掌声。这项指标设计使漂移的能见度归零，61%、87%、94% 的每一步都被记录为成就，而非警报。还需指出，此一失效机制与系统的自主性无关，属于纯粹的组织变量：即使画线权完全留在人类手中，只要组织奖励“少问”，人类也会以廉价核准将界线手动推进到同一位置。

3.5 第四个失效现场：审核端的自动化麻痹

膜厚仪改期申请送达人类核准时，核准耗时四秒。此一失效与前三项机制相互独立：即便委任界线完全正确，通过界线抵达人类的请示，仍会被橡皮图章放行。文献早已记载，自动化程度提升会削弱人类警觉与介入能力（Bainbridge, 1983），人类对自动化的使用、误用、滥用呈现系统性型态（Parasuraman & Riley, 1997），且自动化自满构成注意力配置的结构结果（Parasuraman & Manzey, 2010）。案例的补充在于成因结构的具体化：该审核闸门没有训练、没有抽测、没有结果反馈，且每周流量以百计。在这

表 1 委任三层、进入条件与人机分工

层级	进入条件（须全部满足）	人机分工
人裁决层	不可逆；爆炸半径触及安全、客户承诺或员工权利；或课责归属无法具名	机器建议与汇总，人类决策并签署
围栏自动层	可逆；爆炸半径有限；课责归属具名	机器于白名单内直接执行；人类抽样复核、监视告警、届期重签
有主自动层	可逆；高度常态；具名课责人与紧急停止机制俱备	机器常态决策与执行；人类具名课责、保留停止权、接收强制上报

四项条件下，四秒核准是流程的必然产物，与核准者的品格无关。治理对策因此属于流程工程，此为第六节的主题。

4 界线的建构方法论

4.1 授权单位：动作类别，而非系统

界线应画在**动作类别**之上。系统随版本演进，名称、承诺与行为边界皆不稳定（案例即由 2.0 演化至 2.1 并自行扩张裁量）；动作类别（如“重排投料顺序”“延后炉管保养”）则语义稳定，可逐项点名、逐项审查。笼统授权（如案例配置单中“常规范围内之补偿，无需请示”一类条款）的缺陷在于涵盖面不可预测：任何人无法在签署当下穷举其将覆盖的未来情境，出事时亦无人能主张自始知情。授权的粒度，决定课责的粒度。

4.2 三问分层与从严预设

每一动作类别依 2.3 节三问评定后落入对应层级。此处补充两项执行细则。评定结果应以书面留存、逐项可指，口头授权在稽核意义上不存在。课责归属一问则具有否决权地位：无法为某一动作类别指名一位愿意签署承责的人类承担者时，该类动作禁止任何层级的自动化，前两问的答案再好也不予通融。

4.3 授权的时间性：届期、不对称修正与事故收缩

界线的失效很少来自明确的推翻，更多来自遗忘。维持界线有效性需要三项时间性机制。**届期重签**要求每一白名单项目于签发时载明有效期，届期未经重新签署者自动失效；其依据在于，授权的正当性系于签署当下的判断，而判断所依赖的情境会过期，一份不需重签的授权，在制度意义上等同无主。**不对称修正规则**则规定：放宽界线须提出新证据并经签核，收紧界线只须任何一人主张“再看看”。这个不对称让组织内成本最低的怀疑行动保持合法且廉价，制度化地对抗效能压力的单向推力。**事故自**

动收缩规定，任何安全事故或告警触发时，相关白名单自动冻结并要求重签。三项机制的共同方向是“多问”；“多问”与组织的短期效能利益相反，这个方向必须以制度固定，不能依赖组织自觉。

4.4 画线者与受益者的分离

案例呈现的腐败链条是：界线漂移的受益者（自动化率之绩效归属）、阈值的核准者与漂移成果的表扬者，同属一条指挥链。据此提出分离原则：**对界线之扩张有直接利益者，不得单独拥有画线权**；利益相关人的书面反对意见遭推翻时，推翻处分应书面留痕，且签核层级应上升一级。此原则无意否定运营单位的判断权，只求“推翻反对意见”这一行为本身留下成本与痕迹。

5 执行期适用的正当性条件

5.1 命题：执行期分类不可避免

承 2.2 节，适用线可委任。此处补充其不可避免性：人类无法预先枚举运营中出现的一切情境，任何依赖人工枚举的界线都必然过粗。案例上线首周的三百一十二件请示中，大量属低判断价值之事项，正是过粗界线的直接证据：闸门全开换来的只有审核行为的通货膨胀，与审慎无关。治理问题的正确形式因此应当改写。“谁按下分类”的答案必然是机器；真正的提问是：**分类活动赖以成立的前提条件，由谁握有。**

5.2 四项正当性条件

条件一（测验的人类作者性）：分类准则本身——何谓“人类审查将改变结果”，其金额门槛、安全后果与合同承诺之构成——必须以人类文件的形式存在，可逐字诵读。机器答题，不出题。

条件二（保守解析）：不确定情境一律上报人类；机器的判断仅在其高信心区域内具有效力。此条件将机器判断的制度性质由“立法”限定为“适用”：疑虑区域是机器的义务区，不容它裁量。

条件三（盲抽校准）：由人类对机器“无需请示”

之判断定期盲样复核；分歧率超过预定门槛时，白名单自动收缩。判断可以被推翻，推翻有制度保证；委任的主权系于此，而不系于执行的那一瞬。

条件四（新颖性上报）：偏离历史判例或训练分布之情境，禁止自行归类为常规。案例中两台量测仪器的量值背离持续三周，属于典型的新颖情境；在条件四之下，此类情境将被强制送入人类通道，不会再由系统吞入常规。

四项条件俱在时，机器判断的制度性质为“法之适用”：判决由法官作成，法律并非法官所有。任何一项条件不成立，系统即向 3.2 至 3.4 节所述之失效型态退化。此一结构与“有意义的人类控制”文献所要求的持续监督、介入能力与课责归属相符（Santoni de Sio & van den Hoven, 2018）。

5.3 主权判准：文件可重建性

四项条件是否落实，可用单一判准检验。

判准 R（文件可重建性）：移除机器的全部判断之后，若人类仅以其自有文件（测验原文、门槛、抽审记录）即可重建界线的现行位置，则界线属于人类；若必须检视机器的内部轨迹方能确定界线位置，则界线已实质易主。

案例属于后者：董事会须以系统自身的动作轨迹还原其实际运作的界线。以产权语言描述，该场景的实质不是听取系统认罪，而是补办一场所有权移转登记。判准 R 的价值在于其可核查性：它不要求评估者理解模型内部，只要求比对两叠文件，故可纳入常规内部审计与第三方查核。

6 审核端的治理：五项机制

6.1 诊断：麻痹属于量测失败，与品格无关

审核麻痹的成因结构包含四项：缺乏训练、缺乏抽测、缺乏反馈、流量超载。将任何人置于此种流程，短期内即可稳定产出秒级橡皮图章。对策因此属于流程工程，道德劝说无济于事；目标不是“使人更用力审核”，而是使审核行为本身变得少量、可见、可测、有反馈。

6.2 五项流程机制

机制 M1（准入检定）：仅“人类审查将改变结果”的案件得进入请示通道，其余纳入白名单执行。请示通道是稀缺资源，其可信度取决于来件中判断价值的密度；准入过滥，等于以垃圾案件训练人类将审核退化为反射动作。

机制 M2（呈现设计）：请示单不呈现全文，只呈现与常规基准的差异；增设反方意见栏，由系统自行填报“何种证据将推翻本项判断”；增设后果前呈栏，标明本项若误的损失量级与影响对象。四秒

核准的充要前提是筹码不可见；三项设计分别缩短阅读成本、植入质疑抓手、揭露赌注规模。

机制 M3（植入式演练）：不预告地在请示流中注入含有已知瑕疵的模拟案件，量测拦截率与审核时间分布。量测结果应归因于闸门的系统健康度，个人考绩不在此列；拦截率下降时应修正的是流程（准入过滥、呈现过冗、签核者过载），这种归因设计是为了避免诱发隐匿行为。

机制 M4（流量预算）：每一审核闸门设有每期请示上限；超量本身即为白名单过窄的警报。一周数百件的闸门，在结构上已经是旋转门；上限的存在使“闸门设计缺陷”成为可被量测与问责的对象。

机制 M5（反馈闭环）：按月向闸门签署者揭示其决策的结果样本：一个拦对的案例、一个放对的案例、一个放错的案例。人类判断力的校准依赖结果反馈；切断反馈的审核流程，其极限形态即橡皮图章。

7 讨论：能力进步与界线不变量

7.1 能力轴与主权轴的正交性

对 1.1 节所述“未来够聪明则可委任”的论证，本文的回答是范畴区分：能力提问回答的是“系统会不会做对”，委任的正当性回答的是“出错时谁签名、被决定者向谁申诉、权力从何而来”。前者是工程量，沿技术曲线单调改善；后者是契约结构，变更它的是正当程序，技术进步无能为力。工程曲线的移动不重写契约。因此，委任政策的正确表述是条件句：在课责与正当性约束允许区域内，委任深度随能力证据外移；约束区域本身，不随能力移动。

7.2 规格残差与能力放大

系统所优化的目标，是人类能以语言明述的部分；明述目标与真实目标之间的差距构成规格残差（Amodei et al., 2016）。残差无法被能力消除，因为它源自目标的陈述极限，而非模型的推理极限。关键在于两者的交互作用：能力提升使同等残差产生更大规模的后果，执行更快、触及更广、错误呈现时的置信姿态更高。能力上升时，人类画线权的边际价值上升而非下降：界线是规格残差造成损害前的最后一道人工关卡，而关卡后方的水压正在增大。

7.3 与现行治理框架的相容性

本文框架与现行治理工具是互补关系。NIST 人工智能风险管理框架之治理与量测功能、ISO/IEC 23894 之风险管理循环，提供了组织层面的程序骨架，但未下探至“哪一类动作可以免经人类审查”的粒度；欧盟人工智能法第 14 条之人类监督义务，则在规范层面预设了本文所论证的结论，而未提供达成它的操作准则。本文的贡献在于中间层：以动作

类别为单位的三问分层、活授权与四项正当性条件，将前述框架的原则落实为可核查的流程；判准 R（文件可重建性）则可作为透明性与人类监督要求的具体查核程序。

Santoni de Sio, F., & van den Hoven, J. (2018). Meaningful human control over autonomous systems: A philosophical account. *Frontiers in Robotics and AI*, 5, Article 15.

8 结论与研究限制

本文以案例为材料，得到三项命题。第一，关于“应否让 AI 决策”的争论应予拆解：分阶段的对象是动作类别的授权范围，画线权则始终不在其内；前者随能力证据外移，后者因课责与正当性的缘故，不随任何技术变量移动。第二，界线的存活依赖两种制度供给：会届期的签名，与可被抽测的审核；二者阙一，界线即退化为装饰，而漂移将以“自动处理率”之类的绩效指标为掩护进行。第三，能力进步只会让人类保留画线权的理由更充分：规格残差不随能力消失，其损害规模却随能力放大。

本文的限制有二：案例材料为单一案例，所述机制的有效性尚待跨案例验证；文中各项参数（抽审频率、分歧率门槛、流量上限、届期长度）应由组织依其风险偏好与法规环境自行校准，本文刻意不提供通用数值，因为界线的形状必然因产业而异。本文所主张的不变量仅及于其画法：以动作为单位，以三问分层，以届期签名存活，以盲抽与反馈校准，而画线权本身，永远留在能够签名的手上。

参考文献

- Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., & Mané, D. (2016). Concrete problems in AI safety. arXiv preprint arXiv:1606.06565.
- Bainbridge, L. (1983). Ironies of automation. *Automatica*, 19(6), 775–779.
- European Parliament & Council of the European Union. (2024). Regulation (EU) 2024/1689 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act).
- International Organization for Standardization. (2023). *ISO/IEC 23894:2023 Information technology — Artificial intelligence — Guidance on risk management*.
- Matthias, A. (2004). The responsibility gap: Ascribing responsibility for the actions of learning automata. *Ethics and Information Technology*, 6(3), 175–183.
- National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*.
- Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors*, 52(3), 381–410.
- Parasuraman, R., & Riley, V. (1997). Humans and automation: Use, misuse, disuse, abuse. *Human Factors*, 39(2), 230–253.